

ABSTRACT

腦中線偏移（Brain Midline Shift, MLS）可以反映腦部病灶（例如外傷性腦損傷、中風、腦瘤或血腫）造成的占位效應（Mass Effect）嚴重程度。MLS 不僅能協助醫師判斷病人是否需要緊急手術，也能用來預測病人的預後。由於 MLS 通常出現在急重症，因此必須快速完成判讀。為此，本研究提出一套以深度學習為基礎的電腦輔助系統，自動偵測腦中線，並結合臨床資料來預測病人的死亡風險。

由於腦中線本身是三維結構，而 CT 影像是一張一張的二維切片，因此直接偵測腦中線並不容易。作者提出一種 **Keypoint Detection（關鍵點偵測）** 方法，在每張 CT 切片上找出中線的關鍵點，再計算每張切片的中線偏移距離（MLS Distance）與偏移面積。接著，再結合臨床資訊，利用 **MLP（多層感知器）** 預測病人的死亡率。

實驗結果顯示，本方法在切片篩選（Slice Selection）具有很高的準確率，預測出的中線距離與偏移體積誤差都很小；偵測出的腦中線與人工標註高度一致（Dice = 0.98）。最後，利用 MLS 與臨床資料建立的 MLP 模型，在死亡率預測上也得到 AUC 超過 0.8 的結果，證明此方法能有效協助病人預後評估。

Intruction

腦中線偏移（Brain Midline Shift, MLS）是一種嚴重的臨床狀況，可能由腦部外傷合併出血、腦中風造成腦水腫、具有占位效應的腦瘤，或其他顱內占位性病灶所引起。MLS 可以透過電腦斷層（CT）、磁共振造影（MRI）或超音波（US）進行測量，但在急性神經疾病或中風病人中，由於 CT 掃描速度快、取得方便，因此最常使用 CT。因此，目前大多數電腦輔助 MLS 偵測方法都是以 CT 影像為基礎。當 MLS 距離超過 5 mm 時，病人通常需要立即接受手術。

傳統上，臨床醫師會透過人工目視方式，挑選中線偏移最大的 CT 切片，或選擇經過 Monroe 孔（Foramen of Monroe）的典型切片來量測 MLS。此外，MLS 也經常被當作評估創傷病人預後的重要量化指標。因此，如果能夠利用深度學習自動且快速地偵測與量化 MLS，不但可以幫助醫師更快完成診斷、及早開始治療，也能降低不同醫師之間量測結果的差異。

然而，造成 MLS 的原因很多，因此要正確偵測 MLS 並不容易。如何準確地偵測與量化 MLS，至今仍然是一項具有挑戰性的工作。腦中線本身是一條將左腦與右腦對稱分隔開來的虛擬曲線。傳統上，醫師會利用五個重要的解剖構造來判斷腦中線，包括

前腦鐮（Anterior Falx，AF）、透明中隔（Septum Pellucidum，SP）、第三腦室（Third Ventricle，V3）、松果體區（Pineal Region，PR）以及後腦鐮（Posterior Falx，PF），如圖 1(a) 所示。

不過，並不是每一張 CT 切片都能同時看到這五個解剖構造。對整個腦部而言，理想的中線應該是一條連接前顱窩中的大腦鐮（Falx）、雞冠（Crista Galli）、額嵴（Frontal Crest），以及後顱窩中的十字隆起（Cruciform Eminence）的曲線，如圖 1(b) 中的藍線所示。真正的中線則是沿著前腦鐮延伸到後腦鐮的一條曲線，用來區分左右腦。變形後的中線距離理想中線最遠的那一點，其垂直距離就定義為 MLS 距離，如圖 1(b) 所示。

如果能利用深度學習找出這條理想中線，我們就可以計算最大的 MLS 距離，同時把每一張 CT 切片上的偏移面積累積起來，進一步估算整個腦部的 MLS 體積（Volume），使 MLS 的量化更完整。

Liao 等人提出了一種以左右對稱為基礎的 MLS 偵測方法。他們將變形後的腦中線分成三個部分：上方直線、中間由 Bézier 曲線形成的彎曲部分，以及下方直線，藉此估計腦中線的位置。在他們的研究中，MLS 的平均絕對誤差（Mean Absolute Error）為 4.0 mm，標準差為 4.4 mm。

Chen 等人提出了一種 Landmark-based 方法，利用 Gaussian Mixture Model（高斯混合模型）以及 Shape Matching（形狀匹配）來尋找腦中線。然而，這類方法所偵測出的中線並不一定平滑，而且在許多 CT 影像中，很難找到五個固定的解剖標記點。即使如此，在真實中線的位置上，仍有超過 80% 的案例誤差小於 2.25 mm。

Jain 等人利用腦組織、腦池（cistern）以及急性顱內病灶的分割結果來偵測 MLS，並以「MLS 是否大於 5 mm」作為分類任務進行評估，其分類準確率達到 0.89。

Xia 等人提出了一套三階段（Three-stage）的深度學習方法，把 Brain Midline 的偵測視為影像分割（Segmentation）問題，同時分析 MLS 與 Glasgow Coma Scale（GCS，格拉斯哥昏迷指數）以及 Glasgow Outcome Scale（GOS，格拉斯哥預後量表）之間的關

係。

Jiang 等人則指出，只在單一 CT 切片上量測 MLS，無法完整反映整個腦組織的位移情況。因此，他們分析了 Brain MLS 的最大偏移距離（Distance）以及偏移體積（Volume）與創傷性腦損傷病人預後之間的關聯。

深度學習與 Keypoint Detection

近年來，深度學習快速發展，已經被廣泛應用於醫學影像中的各種任務，例如目標偵測（Detection）與影像分割（Segmentation）。

Keypoint Detection（關鍵點偵測）是深度學習的重要應用之一，常見於人體姿勢估計（Human Pose Estimation），例如臉部特徵點或人體骨架關節的偵測。這種方法最重要的要求，就是每一個關鍵點的位置都必須非常精確。

Keypoint Detection 大致有兩種做法：

第一種是直接預測每一個關鍵點的座標（Coordinate Regression）。

第二種則是預測每一個關鍵點對應的 Heatmap，例如 Mask R-CNN 與 OpenPose 都屬於這種方法。

第二種 Heatmap 方法，也可以視為一種 Semantic Segmentation（語意分割）問題。因此，目前已有許多深度神經網路被設計來完成這類工作，例如 FCN、U-Net 以及 SegNet。

Ronneberger 等人提出了著名的 U-Net 架構，它是一種 U 字型神經網路，並在 2015 年 IEEE ISBI 細胞追蹤競賽中獲得優異成果。直到現在，U-Net 仍然是醫學影像分割最常使用的模型之一。

Keypoint Detection 與 Brain Midline Detection 有一個共同點：

Brain Midline 必須通過的一些位置，其實可以視為一連串的 Keypoints。

因此，只要能準確偵測出這些 Keypoints，就能重建整條 Brain Midline。

作者提出的方法

基於上述原因，我們提出了一種以 **Modified U-Net** 為基礎的 Keypoint Detection 方法，利用深度神經網路直接偵測整個腦部的 Brain Midline。

我們的方法同時結合了 Landmark-based 方法以及 Deep Learning 方法的優點。首先在每一張 CT Slice 上完成 Brain Midline 偵測，再將所有包含 Brain Midline 的切片整合起來，計算整體的 Brain MLS 最大偏移距離（Shift Distance）以及偏移體積（Shift Volume）。

同時，我們另外建立了一套預後預測（Prognosis Prediction）模型，利用 Brain MLS 以及臨床資訊（Clinical Information）來預測病人的死亡狀態（Mortality）。本研究的主要貢獻將於下一節進一步說明。

第二章 Materials and Methods

2. Materials and Methods（完整翻譯）

本研究的研究計畫已通過本院人體研究倫理審查委員會（Institutional Review Board, IRB）審核與核准，允許研究團隊回溯性分析 2015 年 7 月至 2022 年 5 月期間所蒐集的急診腦部 CT 影像。IRB 核准編號為 A-ER-111-185。由於本研究使用的是回溯性資料，且所有病人資料皆已匿名化，因此 IRB 同意免除受試者知情同意（Waiver of Informed Consent）。

2.1 Dataset（資料集）

本研究使用了 兩個彼此獨立的資料集。

第一個資料集為 **Brain MLS 偵測與量化資料集**。研究團隊收集了成功大學醫院急診室中 **20 歲以上**病人的非顯影腦部 CT（Non-contrast Head CT）。為了建立 Brain MLS 偵測模型，研究人員從醫院放射科報告系統中篩選出 **69 組被診斷具有 Brain Midline Shift 的 CT 影像**。

此外，另外回溯性收集 **10 位正常腦部病人** 的 CT，作為評估正常 Brain MLS 範圍之用。

第二個資料集則是 **預後預測（Prognosis Prediction）資料集**。此資料集收集所有放射科報告中診斷為腦出血（Brain Hemorrhage）的病人，用來建立死亡率預測模型。

收集的資料包括：

- 性別（Sex）
- 年齡（Age）
- 是否接受緊急手術（Emergency Surgery）

- 腦出血種類 (Type of Brain Hemorrhage)
- 住院天數 (Hospital Length of Stay)
- 最終死亡狀態 (Alive 或 Dead)

這兩個資料集將分別於 2.1.1 與 2.1.2 詳細介紹。

2.1.1 MLS Detection and Quantification Dataset (完整翻譯)

研究團隊透過放射科報告系統，共收集 69 組 Brain Midline Shift 病人的 Head CT。

每組 CT：

- Slice Thickness (切片厚度) 皆為 5 mm
- 每位病人大約有 30 張 CT Slice
- 每張 CT 影像大小均為 512 × 512 pixels

每一張 CT Slice 的 Ground Truth，包括：

- 理想中線 (Ideal Midline)
- 偏移中線 (Deformed Midline)
- Shift Distance

都是由一位具有 30 年經驗的放射技術師 (CSL) 人工標註，再由一位具有 20 年經驗的放射科醫師 (YST) 再次檢查並修正，以確保標註品質。

理想中線 (Ideal Midline) 是利用可以辨識的解剖構造所建立，包括：

- Falx (大腦鐮)
- Crista Galli (雞冠)
- Frontal Crest (額嵴)
- Cruciform Eminence (十字隆起)

由頭部一路延伸至尾端形成完整的理想中線。

（接下來是 Table 1，作者不是敘述，而是用表格呈現。）

Table 1（完整翻譯）

預後資料集基本統計

總共有：

- 存活（Alive）：1915 人
- 死亡（Dead）：313 人

平均年齡：

- 存活： 63.2 ± 17.8 歲
- 死亡： 67.7 ± 15.3 歲

（死亡組平均年齡較高，具有統計顯著差異。）

Brain MLS 最大偏移距離：

- 存活：5.06 mm
- 死亡：9.52 mm

（死亡組偏移距離明顯較大。）

Brain MLS Volume：

- 存活： 16.69 cm^3
- 死亡： 27.46 cm^3

（死亡病人的偏移體積也明顯較大。）

另外作者也比較：

- Gender（性別）
- IPH（腦實質出血）
- SAH（蜘蛛網膜下腔出血）
- SDH（硬腦膜下出血）
- EDH（硬腦膜外出血）
- IVH（腦室內出血）
- Surgery（是否接受手術）

等臨床變數在存活組與死亡組之間的差異，並利用 t-test 或卡方檢定（Chi-square test）分析是否具有統計顯著性。

2.1.2 Prognosis-predicting Dataset（預後預測資料集）

為了驗證本研究提出的方法，研究團隊另外建立了一個包含 2,228 位腦出血病人的資料集，所有病人皆來自急診室。

這些病人的 CT 影像皆由 Siemens 電腦斷層掃描儀取得，其中：

- 1,780 位病人使用 SOMATOM Definition Flash
- 448 位病人使用 SOMATOM Definition AS 掃描。

本研究利用所提出的模型預測每位病人的 MLS Distance（中線偏移距離）與 Shift Volume（偏移體積），再結合人口學資料與臨床資訊，包括：

- 年齡（Age）
- 性別（Sex）
- 是否曾接受手術（Previous surgery）
- 五種腦出血類型：
 - IPH（腦實質出血）
 - IVH（腦室內出血）

- SAH（蜘蛛網膜下腔出血）
- EDH（硬腦膜外出血）
- SDH（硬腦膜下出血）

利用這些資訊來預測病人的預後（存活或死亡）。

研究中排除了 20 歲以下的病人，因為兒童的大腦仍處於發育階段，其腦部結構與成人有明顯差異。

此研究族群的人口學與臨床特徵整理於 Table 1。

整個資料集病人的年齡介於 21 至 99 歲，平均年齡為 63.8 歲。

其中：

- 男性 1,244 人（55.8%）
- 女性 984 人（44.2%）

病人的預後結果為：

- 存活 1,915 人（86%）
- 死亡 313 人（14%）

是否曾接受手術：

- 有接受手術 654 人（29.3%）
- 未接受手術 1,574 人（70.7%）。

2.2 Modeling for Midline Detection（中線偵測模型）

本研究提出的 Brain Midline Detection（腦中線偵測）架構如 Figure 2 所示。

整個方法可分為兩大部分：

1. Midline Prediction（腦中線預測）

2. Prognosis Prediction（預後預測）。

我們的方法不再採用傳統利用 **五個解剖 Landmark** 的方式，而是將整條 Brain Midline 平均分成 **10 個等分**，形成 **11 個 Keypoints（關鍵點）**。將這 11 個點依序連接成折線（polyline），可以使預測出的中線更加接近真實的 Ground Truth Midline。

每一張 CT Slice 都會輸入 Midline Detection Model，由模型預測 **11 個 Keypoints**，並輸出 **11 張 Heatmaps**。再根據這些 Heatmaps 計算出每一個 Keypoint 的座標。理論上，只要依序將這 11 個座標連接起來，就可以重建整條 Brain Midline。

然而，由於模型本身存在一定限制，在沒有 Brain Midline 的 CT Slice 上，預測出的 Keypoints 順序可能會混亂。因此，本研究利用這個特性，進一步篩選真正包含 Brain Midline 的 CT Slice。完成 Slice Selection（切片篩選）後，即可計算每位病人的最大 MLS Distance 與總 Shift Volume。

傳統 MLS 的量測方式，是在軸向（Axial）Brain CT 上，利用五個解剖位置（AF、SP、V3、PR、PF）建立中線。而其他切片的中線，則是依照大腦鐮（Falx）、雞冠（Crista Galli）、額嵴（Frontal Crest）一直延伸到十字隆起（Cruciform Eminence）所形成的曲線來定義。

在本研究中，Brain Midline 被平均分成 **10 個等長區段**，因此每張 CT Slice 的中線共有 **11 個 Keypoints**（如 Figure 3 所示）。因此，本研究提出一套以 **Keypoint Detection** 為基礎的方法，用來偵測這 11 個關鍵點。

2.2.1 Model Architecture（模型架構）完整翻譯

本研究所提出的 **Keypoint Detection Network（關鍵點偵測網路）** 是以 U-Net 架構為基礎。U-Net 是一種 U 字型神經網路，其架構可分為三個部分：

- Encoder（編碼器）
- Bottleneck（瓶頸層）
- Decoder（解碼器）

Encoder 的主要功能，是從輸入影像中擷取特徵（Feature），並在每一次卷積（Convolution）與池化（Pooling）之後逐漸縮小影像尺寸。

Bottleneck 的功能，是學習輸入資料經過壓縮後的特徵表示（Compressed Representation）。

接著，Decoder 會利用 Bottleneck 的輸出，重新建構出與輸入影像大小相同的新影像。

U-Net 使用 **Skip Connection（跳躍式連接）** 將 Encoder 與 Decoder 直接連接，因此 Decoder 可以重新利用 Encoder 所保留下來的重要資訊。

然而，在深度神經網路的訓練過程中，部分資訊仍然可能因為 **Up-sampling（上採樣）** 與 **Pooling（池化）** 而遺失，因此模型在學習 Keypoints 時可能受到影響。

為了解決這個問題，本研究另外加入 **Dilated Convolution（空洞卷積）** 與 **Residual Learning（殘差學習）**，以改善上述缺點。

一般卷積（Convolution）與空洞卷積（Dilated Convolution）的差異，在於所使用的卷積濾波器（Filter）不同。

空洞卷積允許卷積核在運算時略過部分像素（Pixel），如 Figure 4 所示，因此可以形成較大的感受野（Receptive Field）。

透過較大的感受野，神經網路可以在**不降低特徵圖空間解析度**的情況下，取得更大範圍的影像資訊。

因此，使用空洞卷積能夠讓模型更精確地學習 Keypoints 的位置。

本研究將 Dilated Convolution 放置於 U-Net 的 Bottleneck 部分，因為我們希望 Bottleneck 能更準確地學習各個 Keypoint 的位置。

Residual Learning（殘差學習）是由 He 等人提出。

他們指出，傳統的深層神經網路（例如 VGG Network）存在 Degradation Problem（退化問題）。

所謂退化問題，是指當網路變得越深時，模型的訓練誤差反而會越來越高，而不是越來越低。

因此，He 等人提出 Residual Learning 來解決這個問題。

一個 Residual Block 可表示為：

$$y = F(x, \{W_i\}) + x$$

其中：

- x 為輸入向量。
- y 為輸出向量。
- $F(x, \{W_i\})$ 表示需要學習的 Residual Mapping（殘差映射）。

He 等人的研究證明，相較於直接學習完整函數，模型更容易學習 Residual Function（殘差函數）。

因此，本研究在模型中加入 Residual Block，以避免深層神經網路的退化問題。

本研究模型的完整架構如 Figure 5 所示。

模型輸入一張大小為 $512 \times 512 \times 1$ 的 CT 影像。

最終輸出大小為 $512 \times 512 \times 11$ 。

其中，輸出的 11 個 Channel，各自對應一個 Keypoint 的 Heatmap

2.2.2 Selection and Calculation（切片篩選與計算）

在完成 Brain Midline 偵測之後，我們必須先判斷這張 CT 影像中是否真的存在 Brain Midline。

由於模型所偵測的 11 個 Keypoints 都位於 Brain Midline 上，因此，當一張 CT Slice 確實包含 Brain Midline 時，這 11 個預測出的 Keypoints 應該依照由上到下的順序排列。

如果預測出的 Keypoints 沒有依序排列，我們便認為該張 CT Slice 並沒有 Brain Midline 結構。

因此，本研究提出的 Slice Selection（切片篩選）方法，是檢查這 11 個 Keypoints 在 y 軸座標是否呈現嚴格遞增（strictly increasing）。

若 y 座標依序遞增，代表這些 Keypoints 排列正確，表示該張 CT Slice 包含 Brain Midline；反之，若 y 座標沒有依序遞增，則表示 Keypoints 排列錯誤，因此判定該張 CT Slice 不包含 Brain Midline。

在完成 Slice Selection 後，便開始計算每一張被選取 CT Slice 的 MLS Distance（中線偏移距離）、Shift Area（偏移面積）以及 Shift Volume（偏移體積）。

我們將第一個 Keypoint 與最後一個 Keypoint 作為預測理想中線（Predicted Ideal Midline）的兩端。

接著，把 11 個 Keypoints 依照順序連接成折線（Polyline），作為預測出的變形中線（Predicted Deformed Midline）。

然後，從預測出的變形中線上，找出距離預測理想中線最遠的點。

該點到預測理想中線的距離，即定義為該張 CT Slice 的 **Shift Distance**，記為 d_i 。

此外，由預測理想中線與預測變形中線所圍成的面積，定義為 **Shift Area**，記為 a_i 。

接著，再將 Shift Area 乘上 CT 的 Slice Thickness（切片厚度），即可得到該張 CT Slice 的 **Shift Volume**，記為 v_i 。

本研究同時在 **Slice-level**（單張切片）與 **Case-level**（整位病人）兩個層級進行分析。

在 Case-level 中，

所有 CT Slice 的 Shift Distance 中，取**最大值**作為該病人的 **MLSD**（Maximum Midline Shift Distance）。

而所有 CT Slice 的 Shift Volume 則全部加總，作為該病人的 **MLSV**（Midline Shift Volume）。

公式（2）

$$MLSD = \max_{ROI} (d_i) \quad MLSD = \max (d_i)$$

中文：

MLSD 等於所有 CT Slice 中最大的 Shift Distance。

公式 (3)

$$v_i = a_i \times \text{Slice Thickness} \quad v_i = a_i \times \text{Slice Thickness}$$

中文：

每一張 CT Slice 的 Shift Volume = Shift Area × Slice Thickness。

公式 (4)

$$MLSV = \sum v_i \quad MLSV = \sum v_i$$

中文：

病人的 MLS Volume (MLSV) 等於所有 CT Slice 的 Shift Volume 全部加總。

2.2.3 Evaluation Metric for Slice Selection (切片篩選評估指標)

本研究使用下列五種評估指標來評估 Slice Selection 的效能：

- Accuracy (準確率)
- Precision (精確率)
- Sensitivity (敏感度, True Positive Rate)
- Specificity (特異度)
- F1-score。

Accuracy、Precision、Sensitivity 與 Specificity 的定義如下，其中：

- TP：True Positive (真正例)

- FP：False Positive（假正例）
- FN：False Negative（假負例）
- TN：True Negative（真負例）。

公式（5）

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN}$$

準確率（Accuracy）= 所有預測正確的數量 ÷ 全部樣本數。

公式（6）

$$Precision = \frac{TP}{TP + FP}$$

Precision（精確率）表示模型預測為正例時，有多少是真的正例。

公式（7）

$$Sensitivity = \frac{TP}{TP + FN}$$

Sensitivity（敏感度）表示所有真正例中，有多少被模型成功找出。

公式（8）

$$Specificity = \frac{TN}{FP + TN}$$

Specificity（特異度）表示所有真正負例中，有多少被模型正確判定為負例。

公式 (9)

$$F1 = \frac{2 \times Precision \times Sensitivity}{Precision + Sensitivity}$$

F1-score 為 Precision 與 Sensitivity 的調和平均，用來綜合評估模型的分類能力。

2.2.4 Evaluation Metric for Midline Detection (中線偵測評估指標)

本研究使用 平均絕對誤差 (Mean Absolute Error, MAE) 與 Dice coefficient (Dice 相似係數) 作為中線偵測模型的評估指標，其定義如下：

公式 (10)

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

其中：

- y_i 為 Ground Truth (人工標註) 的 MLS 距離或 MLS 體積。
- $\hat{y}_i$ 為模型預測出的 MLS 距離或 MLS 體積。

公式 (11)

$$Dice = \frac{2 \times TP}{2 \times TP + FP + FN}$$

Dice coefficient 用來衡量模型預測結果與 Ground Truth 的重疊程度。

然而，只使用 Shift Volume 的 MAE 作為評估指標並不足夠，因為 MAE 只能反映數值大小的差異，無法反映 Ground Truth 與模型預測在空間位置上的差異。

因此，本研究另外採用 Dice coefficient 作為 Shift Volume 的評估指標。

Brain Midline 會把整個腦部分成左半腦與右半腦（如 Figure 6 所示）。

為了計算 Dice coefficient，研究人員首先利用 Pixel Threshold（像素閾值）將腦組織從頭骨中分離出來，因為腦組織與頭骨的像素值存在一定差異。

接著，再利用 Morphology（形態學）方法找出最大的連通區域（Maximum Connected Component），作為腦組織區域。

最後，分別計算左半腦與右半腦的 Dice coefficient，以驗證模型預測出的 Brain Midline 與 Ground Truth Midline 的相似程度。

本研究同時計算：

- Slice-level Dice（每張 CT Slice 的 Dice 平均值）
- Case-level Dice（將同一位病人的所有 CT Slice 合併後，再計算 Dice 的平均值）。

2.3 Prognosis-predicting Cohort Study（預後預測世代研究）

如前所述，本研究世代研究（Cohort Study）的目的，是預測病人的死亡率（Mortality），也就是將病人分類為存活（Alive）或死亡（Dead）。

由於 2.1.2 節所建立的世代資料集中，存活與死亡病人的比例並不平衡，因此研究人員先利用 **K-means Clustering**，確保交叉驗證（Cross-validation）每一個 Fold 都具有相似的資料分布，使模型能在每一次訓練時，都學習到兩類病人的代表性資料。

此外，本研究也採用了**資料平衡**（Data Balancing）方法來處理資料不平衡問題。

在訓練 MLP 模型之前，也先進行了**特徵選擇**（Feature Selection）。

2.3.1 Data Balancing（資料平衡）

由於本研究的世代資料集中，存活病人的數量遠多於死亡病人，因此模型在訓練時，可能會偏向學習**多數類別**（Majority Class），而忽略真正重要的**少數類別**（Minority Class），也就是死亡病人。

為了解決這個問題，本研究採用了 **Resampling**（重新取樣）方法，包括：

- **Oversampling**（過度取樣）
- **Undersampling**（不足取樣）。

Oversampling 的作法，是增加少數類別（死亡病人）的樣本數。

相反地，Undersampling 則是刪除部分多數類別（存活病人）的樣本。

在資料前處理階段，本研究分別測試 **Random Oversampling** 與 **Random Undersampling**，以找出最適合本研究模型的資料平衡方式。

2.3.2

去

一般而言，特徵選擇（Feature Selection）的方法很多，可分為：

- Filter Method（過濾法）
- Wrapper Method（包裝法）
- Embedded Method（嵌入法）。

由於 **Filter Method** 不依賴任何分類器，而且計算成本較低、速度較快，因此本研究採用 **Filter Method** 作為特徵選擇的方法。

本研究以 卡方檢定（Chi-square Test）或 t-test 所得到的 **p-value** 作為篩選依據。

在 Table 1 中，所有 **p-value** 大於 0.05 的變數，都會被移除，不再作為模型的輸入特徵。

下一段就是 2.3.3 Multilayer Perceptron（MLP），作者會開始完整介紹死亡率預測模型的架構，包括：

- MLP 的原理
- Backpropagation
- 為什麼輸入層是 6 個特徵
- 為什麼 Hidden Layer 設計成 $1024 \rightarrow 512 \rightarrow 256 \rightarrow 64 \rightarrow 32$
- 最後的輸出層如何進行二元分類（Alive／Dead）。

2.3.3 Multilayer Perceptron（多層感知器，MLP）

多層感知器（Multilayer Perceptron，MLP）是一種人工神經網路（Artificial Neural Network，ANN）。一個 MLP 至少包含三個部分：

- 輸入層（Input Layer）
- 隱藏層（Hidden Layer）
- 輸出層（Output Layer）

並且使用**非線性活化函數（Nonlinear Activation Function）**來提升模型的學習能力。

MLP 的每一層神經元之間皆採用**全連接（Fully Connected）**方式相互連結，每一條連線都具有對應的權重（Weight）。

MLP 會透過**反向傳播（Backpropagation）**技術，不斷更新各個神經元之間的權重，使模型逐漸從資料中學習。

反向傳播（Backpropagation）的原理，是計算**損失函數（Loss Function）**對於神經網路各個權重的梯度（Gradient），再利用梯度更新權重，使模型的預測結果逐漸接近真實答案。

本研究所使用的 **MLP 模型** 如 Figure 7 所示。

為了學習病人的死亡狀態（Mortality Status），本研究建立了一個六層（6-layer）MLP 模型。

模型的**輸入層（Input Layer）**共有 6 個輸入特徵（Input Features）。

接著依序連接五個隱藏層（Hidden Layers），各層神經元數量分別為：

- 1024
- 512
- 256
- 64
- 32。

由於本研究的預測目標屬於二元分類（Binary Classification）問題，因此輸出層（Output Layer）只包含一個神經元（Single Node），用來輸出病人屬於「存活（Alive）」或「死亡（Dead）」的預測結果。

2.3.4 Model Evaluation（模型評估）

為了評估預後預測模型（Prognosis Prediction Model）的效能，本研究同樣使用以下評估指標：

- Accuracy（準確率）
- Precision（精確率）
- Sensitivity（敏感度）
- Specificity（特異度）
- F1-score
- AUC（Area Under the ROC Curve，ROC 曲線下面積）。

由於死亡率預測屬於二元分類問題，因此 ROC Curve（Receiver Operating Characteristic Curve）可用來觀察不同分類閾值（Threshold）下模型的整體分類能力，而 AUC 則作為模型整體分類能力的量化指標。

AUC 越接近 1，代表模型的分類能力越好。

第 3 章 Results

3.1 Slice Selection（切片篩選結果）

Slice Selection（切片篩選）的實驗結果列於 Table 2。

本研究提出的方法在切片篩選上具有很高的準確性，其 Accuracy、Precision、Sensitivity、Specificity 及 F1-score 分別達到：

- Accuracy : 0.966
- Precision : 0.952
- Sensitivity : 0.991
- Specificity : 0.932
- F1-score : 0.971

這表示模型幾乎都能正確判斷一張 CT Slice 是否包含 Brain Midline。

Figure 8 顯示 Slice Selection 的實際結果。

可以看到，大部分真正包含 Brain Midline 的 CT Slice 都能被模型正確選出，而沒有 Brain Midline 的切片則會被排除，因此後續 MLS 的量測只會在真正有中線的切片上進行。

3.2 Midline Detection（中線偵測結果）

Brain Midline Detection 的結果如 Table 3 所示。

左半部列出了 Shift Distance 的 Ground Truth、Prediction 與 MAE；右半部則列出了

Shift Volume 的 Ground Truth、Prediction 與 MAE，並分別在 Slice-level 與 Case-level 進行比較。

Slice-level（單張切片）

Ground Truth：

- Shift Distance： 9.479 ± 5.214 mm
- Shift Volume： 3.258 ± 1.802 cm³

模型預測：

- Shift Distance： 8.382 ± 4.815 mm
- Shift Volume： 2.816 ± 1.411 cm³

平均絕對誤差（MAE）：

- Shift Distance： 2.175 ± 2.386 mm
- Shift Volume： 0.613 ± 0.742 cm³。

Case-level（整位病人）

Ground Truth：

- MLSD： 13.344 ± 5.283 mm
- MLSV： 34.218 ± 19.409 cm³

模型預測：

- MLSD： 12.340 ± 5.618 mm
- MLSV： 29.576 ± 15.306 cm³

平均絕對誤差（MAE）：

- MLSD： 2.496 ± 2.581 mm

- MSLSV : $4.539 \pm 5.714 \text{ cm}^3$ 。

Figure 10 顯示 Brain Midline 的預測結果。

圖中的紅線代表人工標註（Ground Truth）的中線，綠線代表模型預測出的中線。

從結果可以看出，模型預測出的中線與人工標註相當接近，表示所提出的方法能夠準確地重建 Brain Midline 。

3.3 不同模型架構比較

Table 4 比較了三種模型架構在 **Slice-level MAE** 上的表現：

1. U-Net
2. U-Net + Residual Block（RB）
3. U-Net + Residual Block + Dilated Convolution（RB + DC，本研究方法）

結果如下：

模型	Shift Distance MAE	Shift Volume MAE
U-Net	9.286 mm	2.479 cm ³
U-Net + RB	6.028 mm	1.087 cm ³
U-Net + RB + DC（本研究）	2.175 mm	0.613 cm ³

實驗結果顯示，在 U-Net 中加入 **Residual Block** 後，模型誤差已明顯下降；再進一步加入 **Dilated Convolution** 後，Shift Distance 與 Shift Volume 的 MAE 都進一步降低，證明本研究提出的改良架構具有最佳的中線偵測能力。

3.4 Dice coefficient（Dice 相似係數結果）

Table 5 列出了本研究 Brain Midline Detection 的 Dice coefficient 結果。

在 **Slice-level** 與 **Case-level** 的評估中，本研究提出的方法皆得到非常高的 Dice coefficient，表示模型預測出的 Brain Midline 與人工標註（Ground Truth）具有高度一致性。

在 Slice-level 的評估中，左半腦與右半腦的 Dice coefficient 均約為 **0.98**。

在 Case-level 的評估中，Dice coefficient 同樣接近 **0.98**，代表模型在整位病人的 Brain Midline 重建上，也具有很好的表現。

Figure 11 顯示數個 Brain Midline 偵測的範例。

在大多數案例中，模型預測出的 Midline 幾乎與 Ground Truth 重合。

即使 Brain Midline 已經產生明顯偏移，模型仍然可以正確追蹤整條 Midline 的位置。

3.5 Prognosis Prediction（預後預測）

為了建立預後預測模型，本研究比較了不同資料平衡（Data Balancing）策略、不同 MLP 架構，以及不同輸入特徵對模型效能的影響。

Table 6：不同 Data Balancing 方法比較

作者比較了：

- 不進行資料平衡（Original）
- Random Oversampling
- Random Undersampling

三種方式。

實驗結果顯示：

Random Oversampling 的整體表現最佳，因此後續所有 MLP 實驗皆採用 Random Oversampling 作為資料平衡方法。

Table 7：不同 Probability Threshold 比較

接著，作者測試不同分類 Threshold 對模型的影響。

Threshold 從 0.1 一直到 0.9 分別進行測試。

結果顯示，不同 Threshold 會影響：

- Accuracy
- Precision
- Sensitivity
- Specificity
- F1-score

綜合比較後，作者選擇最適合本研究資料集的 Threshold 作為後續模型設定。

Table 8：不同 Hidden Layer 比較

作者另外比較了不同 Hidden Layer 架構，例如：

- 128
- 256
- 512
- 1024
- 多層 Hidden Layer

對 MLP 預測能力的影響。

最後發現，本研究採用的 $1024 \rightarrow 512 \rightarrow 256 \rightarrow 64 \rightarrow 32$ 五層 Hidden Layer，在整體 Accuracy 與 AUC 上表現最佳，因此作為最終模型。

Table 9：不同輸入特徵比較

最後，作者比較三種不同輸入方式：

1. MLP + MLSD
2. MLP + MLSD + MLSV
3. MLP + MLSD + MLSV + Clinical Information

評估它們對死亡率預測的影響。

(1) 只使用 *MLSD*

- Accuracy : 0.809 ± 0.032
- Precision : 0.415 ± 0.060
- Sensitivity : 0.578 ± 0.028
- Specificity : 0.851 ± 0.039
- F1-score : 0.477 ± 0.038
- AUC : 0.767 ± 0.017 。

(2) 使用 *MLSD + MLSV*

- Accuracy : 0.808 ± 0.016
- Precision : 0.406 ± 0.023
- Sensitivity : 0.561 ± 0.077
- Specificity : 0.852 ± 0.030
- F1-score : 0.468 ± 0.027

- AUC : 0.766 ± 0.025 。

(3) 使用 *MLSD + MLSV + Clinical Information*

- Accuracy : 0.813 ± 0.015
- Precision : 0.417 ± 0.026
- Sensitivity : 0.597 ± 0.086
- Specificity : 0.851 ± 0.026
- F1-score : 0.488 ± 0.040
- AUC : 0.781 ± 0.041 。

根據實驗結果，加入 **Clinical Information (臨床資訊)** 後，模型在 Accuracy、Sensitivity、F1-score 與 AUC 均獲得最佳表現。

因此，作者認為除了 Brain MLS 的影像資訊之外，結合臨床資料能夠進一步提升死亡率預測的能力。

第 4 章 Discussion (Part 1)

根據本研究 Slice Selection (切片篩選) 的結果，**False Negative (偽陰性) 與 False Positive (偽陽性)** 案例值得特別討論，因為這兩種錯誤都可能影響 **MLSD (最大中線偏移距離)** 與 **MLSV (中線偏移體積)** 的計算結果。

Figure 8 顯示了三個 False Negative 的案例。

在這些 CT 切片中，其實可以清楚看到 Brain Midline，但模型卻沒有將它們判定為包含 Brain Midline 的切片，因此被錯誤排除。

造成這種情況的原因是，這些切片中的 11 個 Keypoints 並沒有依照由上到下的順序排列。

依照本研究 Slice Selection 的規則，只要 Keypoints 的順序發生錯亂，就會被判定為「沒有 Brain Midline」，因此形成 False Negative。

Figure 9 則顯示三個 False Positive 的案例。

在這些 CT 切片中，其實並沒有真正的 Brain Midline，但模型仍然預測出一組排列正確的 Keypoints，因此誤判為包含 Brain Midline。

雖然 Slice Selection 並非百分之百正確，但本研究仍達到 96.6% 的 Accuracy，因此這些 False Positive 與 False Negative 對整體模型造成的影響相對有限。

在 Brain Midline Detection 的實驗中，本研究分別以 **Slice-level** 與 **Case-level** 進行評估。

在 Case-level 中，利用 **MLSD** 與 **MLSV** 代表每位病人的 Brain Midline Shift。

Table 3 的結果顯示，本研究提出的方法在 **Slice-level** 的 MLS Distance 平均誤差約為 **2 mm**，MLS Volume 平均誤差約 **1 cm³**。

在 **Case-level**，MLSV 的平均誤差約為 **5 cm³**。

Figure 10 展示了一個成功偵測 Brain Midline 的案例。

模型所預測出的 Midline 與人工標註非常接近，顯示本研究提出的方法能夠有效完成 Brain Midline Detection。

本研究也將所提出的方法與 **原始 U-Net** 以及 **加入 Residual Block 的 U-Net** 進行比較。

如 Table 4 所示，在 U-Net 中加入 **Residual Block** 與 **Dilated Convolution** 後，中線偵測效能都有明顯提升。

此外，本研究也利用 **10 組正常腦部 CT** 進行測試 (Figure 11)。

Brain Midline Shift 病人的平均 MLS Distance 為 $12.340 \pm 5.618 \text{ mm}$ ，而正常腦部的平均 MLS Distance 為 $2.289 \pm 0.765 \text{ mm}$ 。

這表示，即使是正常人的 Brain Midline，也可能存在些微偏移，而不是完全位於正中央。

Figure 12 顯示，本研究提出的方法對於 **Brain Midline Shift 較大的病例**，仍然能夠維持良好的偵測能力。

Table 5 的 Dice coefficient 結果顯示，不論是 **Slice-level** 或 **Case-level**，Dice coefficient 都達到 **0.98**。

綜合以上結果，本研究提出的 Midline Detection Model 在 **Slice Selection** 與 **Brain Midline Detection** 兩項工作上，都具有良好的效能。

第 4 章 Discussion (Part 2)

在預後預測 (Prognosis Prediction) 的世代研究中，不同資料前處理策略下的 MLP 模型表現如 Table 6、Table 7 與 Table 9 所示。

Table 6 顯示，採用 Random Undersampling（隨機欠採樣）的結果並不理想。

這是因為隨機欠採樣後，保留下來的訓練資料數量太少，使得 MLP 無法從有限的資料中學習到足夠的特徵，因此整體準確率只有約 0.5。

雖然本研究利用 K-means Clustering 與 Oversampling（過採樣）來改善資料不平衡問題，但在 Precision（精確率）、Sensitivity（敏感度）與 F1-score 等指標上，仍然沒有達到非常理想的結果。

Table 7 顯示，不同的 Threshold（分類閾值）會造成不同的模型表現。

本研究偏好選擇 Sensitivity 與 Specificity 較為平衡的模型，因為研究團隊不希望模型產生過多的 False Negative（偽陰性）或 False Positive（偽陽性）。

與文獻 [11] 相比，本研究中 中度 (Moderate) 與 重度 (Severe) GCS 病人的 MLSD 與 MLSV，和死亡病人的結果相當接近。

本研究發現，相較於 MLSD (最大中線偏移距離)，MLSV (中線偏移體積) 對病人預後具有較好的預測能力。

比較 Table 9 中只使用 MLSD 的模型，與同時使用 MLSD + MLSV 的模型可以發現，加入 MLSV 作為訓練特徵後，模型效能有些微提升。

然而，本研究中 MLSV 的提升幅度，並不像文獻 [11] 所報告的那麼明顯。

此外，由 Table 7 的結果以及 Figure 13 的綠色 ROC 曲線可以

看出，加入臨床資訊（Clinical Information）作為訓練特徵後，模型的預測能力確實獲得明顯改善。

本研究提出了一套 三階段（Three-stage）方法，也是第一個能夠自動偵測整個腦部 Brain Midline 的方法。

第一階段，模型先對 CT 影像中的每一張切片進行 Brain Midline 偵測。

第二階段，自動挑選真正包含 Brain Midline 的 CT Slice。

第三階段，根據所有被選出的切片，自動計算整個腦部的 MLS Distance 與 MLS Volume。

整個流程皆為全自動（Fully Automatic），而且只需要一個 Midline Detection Model 即可完成，不需要額外建立其他模型或進行人工修正。

儘管如此，本研究仍有一些限制（Limitations）。

首先，本研究僅使用**單一醫學中心**的資料，因此仍需要利用其他醫院的資料來驗證模型的泛化能力（Generalizability）。

第二，本研究主要針對**成人病人**建立模型，因此是否能應用於兒童病人，仍需進一步研究。

第三，本研究的死亡率預測模型僅使用 **Brain MLS** 與部分臨床資訊，未來仍可加入更多臨床變數，例如實驗室檢驗結果或其他影像特徵，以進一步提升預測能力。

第 5 章 Conclusions（結論）

本研究提出了一種以**關鍵點偵測模型**（Keypoint Detection Model）為基礎的深度學習方法，用於偵測腦部中線偏移（Brain Midline Shift, MLS），並進一步量化腦部中線偏移的距離（MLS Distance）與體積（MLS Volume）。

本研究所提出的方法，在切片篩選（Slice Selection）方面具有很高的準確率（Accuracy）、精確率（Precision）與敏感度（Sensitivity），並且展現出良好的能力，能

夠準確地偵測及量化腦部中線偏移。

本研究將中線偵測模型所得到的結果，進一步應用於**病人預後（Prognosis）**的預測。

實驗結果顯示，利用腦部中線偏移資訊結合臨床資料，可以有效預測病人的死亡風險，顯示本方法具有作為**電腦輔助診斷（Computer-Aided Diagnosis, CAD）**工具的潛力。

我們未來的最終目標，是建立一套能夠協助**臨床醫師及病人家屬**進行醫療決策的系統。

這套系統將能夠根據：

- 醫學影像（Medical Images）
- 臨床資料（Clinical Data）
- 手術死亡機率（Probability of Surgical Mortality）

提供客觀的評估結果，作為臨床決策的參考依據。